



Tecnológico de Monterrey

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

**Momento de Retroalimentación: Módulo 2 Análisis y Reporte
sobre el desempeño del modelo. (Portafolio Análisis)**

Carlos Manuel Delgado Vázquez

Matrícula: A01747037

IDM

Repositorio: https://github.com/CDV-97/M2_ML.git

Objetivo

El objetivo de esta actividad fue analizar el desempeño del modelo de Árbol de Decisión implementado con scikit-learn, utilizando conjuntos separados de entrenamiento, validación y prueba. El análisis se enfocó en identificar el nivel de sesgo, varianza y ajuste del modelo, además de aplicar técnicas de regularización y ajuste de parámetros para mejorar su desempeño.

Dataset utilizado

Se utilizó nuevamente el dataset Water Potability, que contiene información fisicoquímica de muestras de agua y una variable objetivo llamada Potability.

Las clases representan:

- 0: agua no potable
- 1: agua potable

Antes del entrenamiento, los valores faltantes fueron reemplazados con la media de cada variable.

Separación Train / Validation / Test

Para evaluar correctamente el comportamiento del modelo, el dataset fue dividido en tres conjuntos:

- **70% entrenamiento**
- **15% validación**
- **15% prueba**

Los tamaños obtenidos fueron:

None

Train: 2293

Validation: 491

Test: 492

El conjunto de entrenamiento se utilizó para ajustar el modelo, el conjunto de validación para analizar su comportamiento y seleccionar ajustes, y el conjunto de prueba para realizar la evaluación final.

Modelo base

El modelo base utilizado fue un Árbol de Decisión con la siguiente configuración:

```
None
DecisionTreeClassifier(
    criterion="gini",
    max_depth=3,
    min_samples_split=2,
    random_state=42
)
```

Los resultados obtenidos fueron:

Conjunto	Accuracy	F1 - score
Train	0.6446	0.3527
Validation	0.6130	0.2520
Test	0.6057	0.2595

Prueba de ejecución

```
Tamaños de los conjuntos:
Train: 2293
Validation: 491
Test: 492

MODELO BASE
Accuracy -> Train: 0.6446 | Validation: 0.6130 | Test: 0.6057
F1-score -> Train: 0.3527 | Validation: 0.2520 | Test: 0.2595
```

El script analysis.py se ejecutó correctamente, realizando la separación de los datos en entrenamiento, validación y prueba, evaluando el modelo base y posteriormente el modelo ajustado.

Diagnóstico de sesgo

El modelo presenta un sesgo alto. Esto se observa debido a que incluso en el conjunto de entrenamiento el desempeño es limitado:

- Accuracy de entrenamiento: **0.6446**
- F1-score de entrenamiento: **0.3527**

Un modelo con bajo sesgo debería alcanzar un mejor desempeño sobre los datos utilizados durante el entrenamiento. Por lo tanto, el modelo base tiene dificultades para capturar completamente los patrones presentes en los datos.

Diagnóstico de varianza

El modelo presenta una **varianza media**. Aunque existe una diferencia entre el desempeño en entrenamiento y validación, esta diferencia no es extrema.

Para F1-score:

None

Train: 0.3527

Validation: 0.2520

La diferencia es aproximadamente:

$$0.3527 - 0.2520 = 0.1007$$

Esto indica cierta sensibilidad a los datos de entrenamiento, pero no un nivel extremo de sobreajuste.


Nivel de ajuste del modelo

El modelo base presenta underfitting. Esto se debe principalmente a dos factores:

1. El desempeño en entrenamiento es relativamente bajo.
2. El desempeño en validación y prueba también es bajo y cercano al de entrenamiento.

Estos resultados indican que el modelo no tiene suficiente complejidad para representar correctamente los patrones del dataset.

Gráfica de Train vs Validation



La gráfica muestra que con profundidades pequeñas el desempeño tanto en entrenamiento como en validación es bajo.

Conforme aumenta max_depth, el desempeño de entrenamiento mejora considerablemente. Sin embargo, después de cierto punto, el desempeño de validación mejora mucho menos, generando una brecha creciente entre ambos conjuntos.

Esto permite observar tres zonas:

- profundidades bajas: underfitting
- profundidades intermedias: mejor equilibrio
- profundidades altas: tendencia a overfitting

```
DIAGNÓSTICO DEL MODELO BASE
Bias / sesgo: ALTO
Varianza: MEDIA
Nivel de ajuste: UNDERFITTING
```

Resultados de ejecución

Ajuste y regularización

Con base en el diagnóstico anterior, se modificaron algunos parámetros del Árbol de Decisión.

El modelo ajustado fue:

```
None
DecisionTreeClassifier(
    criterion="gini",
    max_depth=5,
    min_samples_split=10,
    min_samples_leaf=5,
    random_state=42
)
```

Los cambios realizados fueron:

- `max_depth`: aumentó de 3 a 5 para permitir que el modelo capture patrones más complejos.
- `min_samples_split`: aumentó de 2 a 10 para evitar divisiones basadas en muy pocas observaciones.
- `min_samples_leaf = 5`: se añadió para evitar hojas demasiado pequeñas y reducir el riesgo de sobreajuste.

De esta forma se incrementó la capacidad del modelo, manteniendo al mismo tiempo cierto nivel de regularización.

Resultados del modelo ajustado

Los resultados obtenidos fueron:

```
MODELO AJUSTADO
Accuracy -> Train: 0.6873 | Validation: 0.6334 | Test: 0.6524
F1-score -> Train: 0.4975 | Validation: 0.3836 | Test: 0.4042
```

En comparación con el modelo base, se observa una mejora en todos los conjuntos.

F1-score

Validation: 0.2520 $\rightarrow$ 0.3836


Test: 0.2595 $\rightarrow$ 0.4042

Accuracy

Validation: 0.6130 $\rightarrow$ 0.6334

Test: 0.6057 $\rightarrow$ 0.6524

Comparación antes y después del ajuste



La gráfica muestra una mejora clara después del ajuste de hiperparámetros. El F1-score aumentó tanto en validación como en prueba, indicando que el modelo ajustado tiene una mejor capacidad para generalizar observaciones no utilizadas durante el entrenamiento. La mejora más importante se observa en el F1-score del conjunto de prueba, que aumentó de aproximadamente **0.26 a 0.40**.

Análisis general

El modelo original presentaba un problema principalmente de alto sesgo y underfitting, ya que su capacidad de aprendizaje era limitada incluso sobre el conjunto de entrenamiento.

La gráfica de profundidad muestra que aumentar la complejidad del árbol permite mejorar el aprendizaje. Sin embargo, profundidades demasiado altas generan una diferencia creciente entre Train y Validation, indicando un incremento de la varianza y una tendencia al overfitting.

Por esta razón, se seleccionó una configuración intermedia que permitiera aumentar la capacidad del modelo sin dejarlo crecer de manera excesiva. El modelo ajustado consiguió mejorar tanto el Accuracy como el F1-score en validación y prueba.

Conclusión

El análisis permitió diagnosticar que el Árbol de Decisión base presentaba:

- Sesgo alto
- Varianza media
- Underfitting

A partir de este diagnóstico se modificaron los hiperparámetros `max_depth`, `min_samples_split` y `min_samples_leaf`. Después del ajuste, el modelo presentó una mejora clara en su capacidad de generalización.

El F1-score en prueba aumentó de **0.2595 a 0.4042**, mientras que el Accuracy aumentó de **0.6057 a 0.6524**. Estos resultados muestran que el ajuste de hiperparámetros permitió obtener un modelo con mejor desempeño y un mejor equilibrio entre capacidad de aprendizaje y generalización.

Link del Dataset

<https://www.kaggle.com/datasets/adityakadiwal/water-potability>